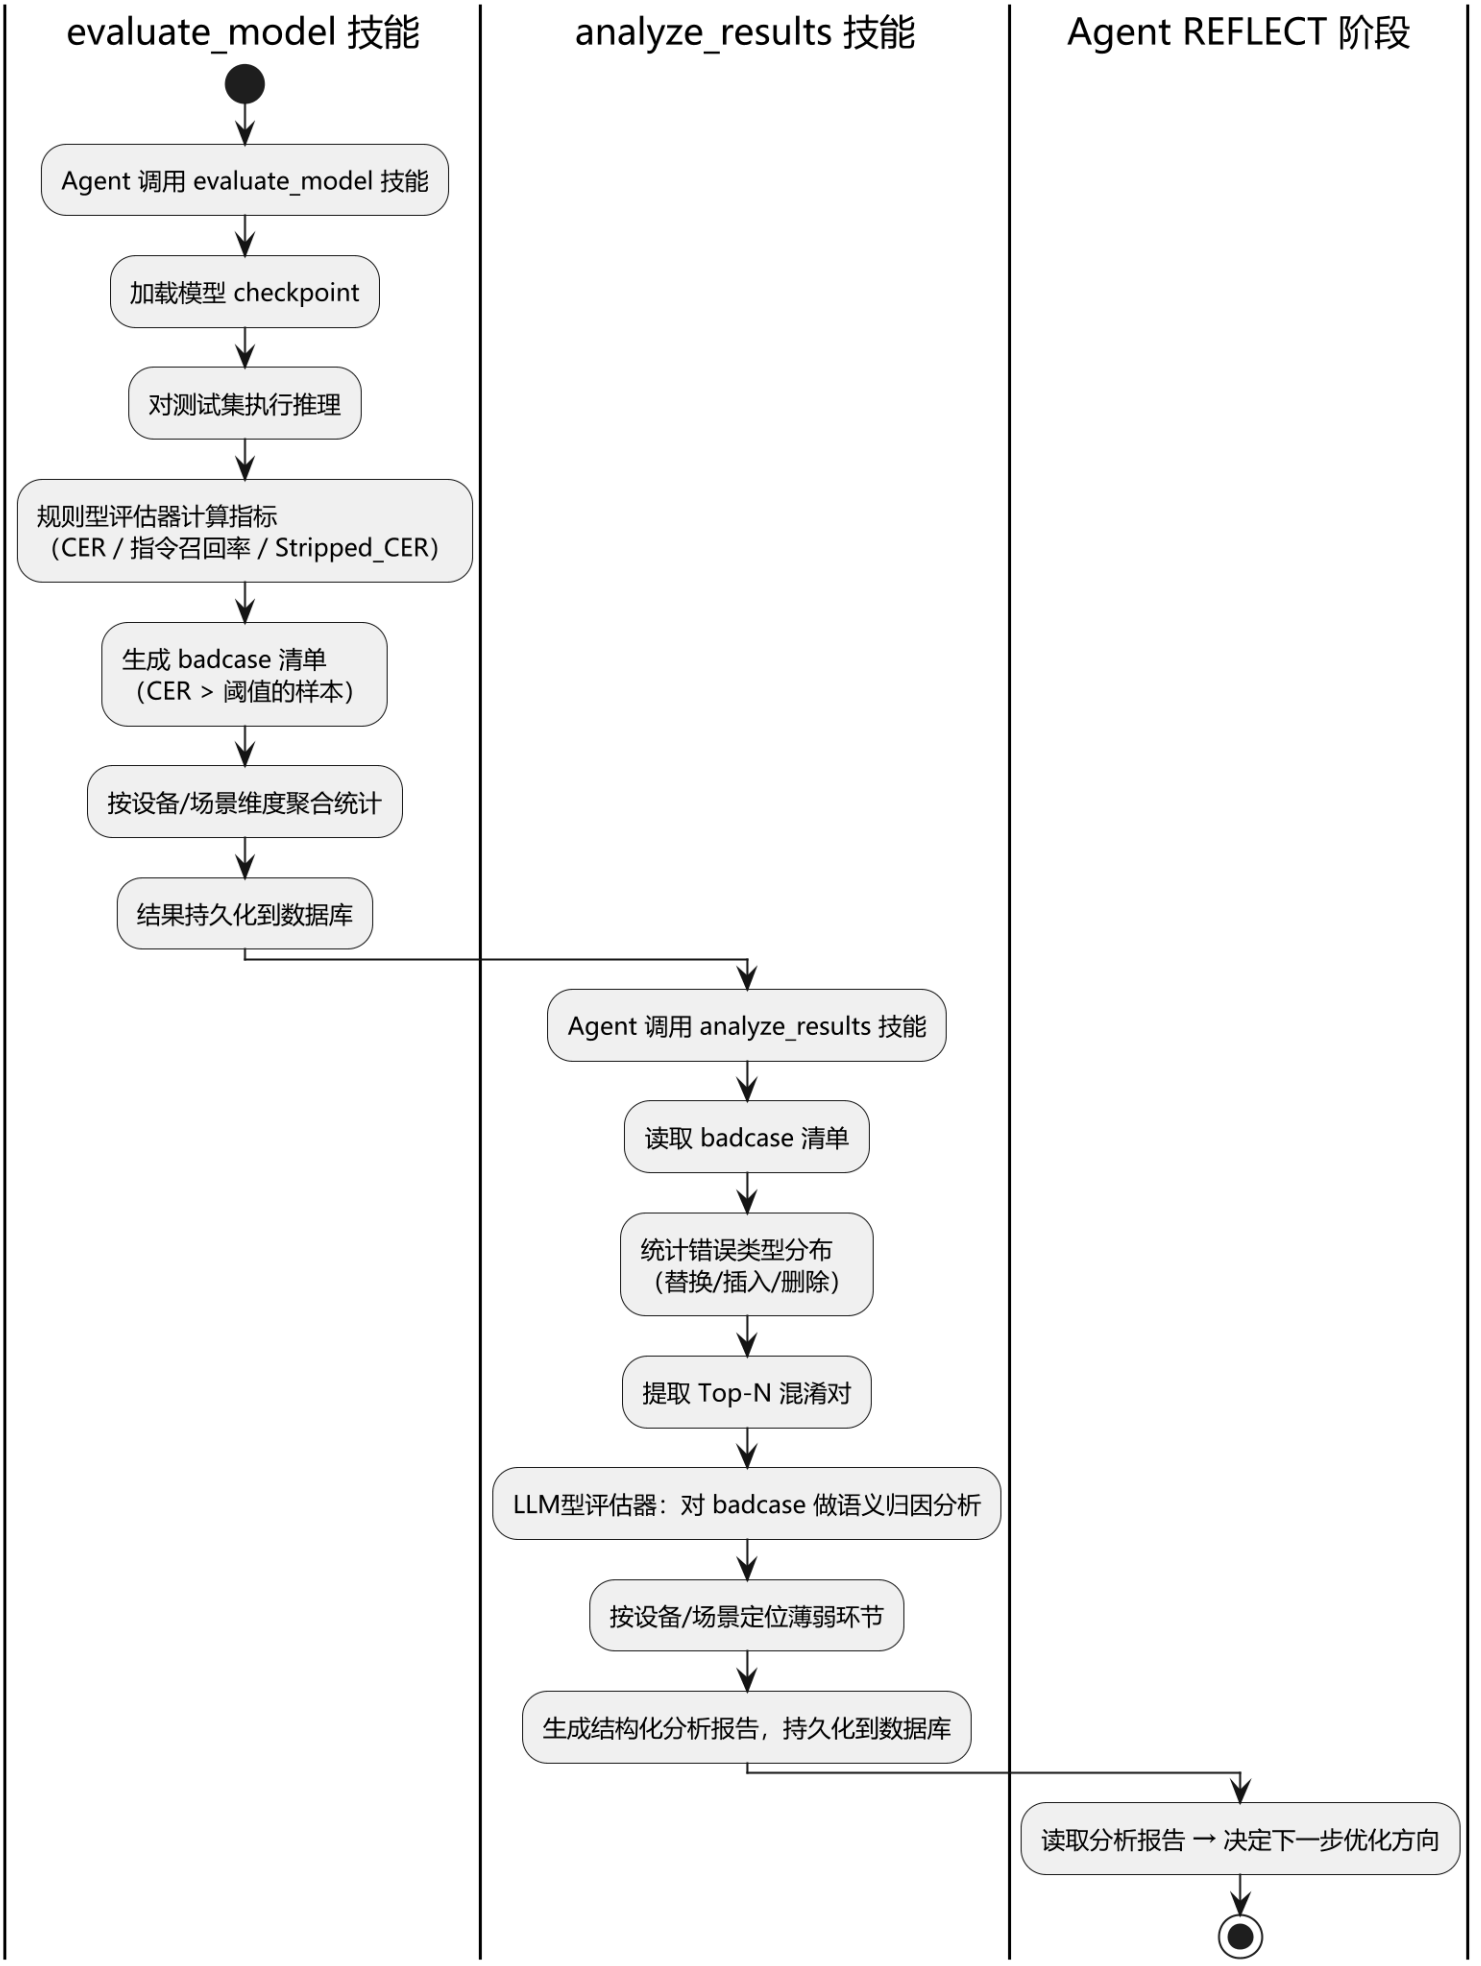

evaluate_model 技能
analyze_results 技能
Agent REFLECT 阶段
Agent 调用 evaluate_model 技能
加载模型 checkpoint
对测试集执行推理
规则型评估器计算指标
（CER / 指令召回率 / Stripped_CER）
生成 badcase 清单
（CER > 阈值的样本）
按设备/场景维度聚合统计
结果持久化到数据库
Agent 调用 analyze_results 技能
读取 badcase 清单
统计错误类型分布
（替换/插入/删除）
提取 Top-N 混淆对
LLM型评估器：对 badcase 做语义归因分析
按设备/场景定位薄弱环节
生成结构化分析报告，持久化到数据库
读取分析报告 → 决定下一步优化方向